

Candidate Journey Analytics

Wie Daten helfen können, Optimierungspotenziale im Recruiting-Prozess sichtbar zu machen

Data Analytics Portfolio Project · Python · Pandas · Statistics · Data Visualization

Ziel

Ziel dieses Projekts war es zu untersuchen, ob und wie sich die Prozessdauer im Recruiting auf Candidate Experience, Kandidatenabbrüche und Recruiting-Aufwände auswirkt – und ob sich daraus datenbasierte Optimierungspotenziale ableiten lassen.

1. Business Understanding

Recruiting kostet Zeit und Geld. Lange Prozesse können Kandidatenverluste erhöhen.

Wo entstehen Verzögerungen – und welche davon sind tatsächlich relevant?

1. Business Understanding - Hypothese

Lange Wartezeiten zwischen Bewerbung, Interview und Angebot erhöhen die Wahrscheinlichkeit eines Kandidatenabbruchs und führen dadurch zu zusätzlichem Recruiting-Aufwand und höheren Prozesskosten.

Je kürzer meine Time to Hire, desto höher ist die OfferAcceptance Rate.

2. Data Understanding

- Entwurf einer Prozesslogik
- Simulation eines Starschemas aus einem Data Warehouse (Dimensions- und Faktentabellen)
- Konzeption & Generierung eines synthetischen Datensatzes mit Unterstützung von ChatGPT
- Daten eingelesen mit Python/Pandas und erste Sichtung

3. Datenverständnis

3.1 Daten einlesen

Einlesen der Daten ***

3.2 Erstes Kennenlernen der Daten - Überblick verschaffen

Sichten der Faktentabelle die grundlegende Struktur ***

```
<class 'pandas.DataFrame'>  
RangeIndex: 25294 entries, 0 to 25293  
Data columns (total 9 columns):  
#   Column              Non-Null Count  Dtype  
---  -  
0   application_id       25294 non-null  str  
1   candidate_id         25294 non-null  str  
2   job_id               25294 non-null  str  
3   channel_id           25294 non-null  str  
4   event_step_number    25294 non-null  int64  
5   event_type           25294 non-null  str
```

3.4 Businessfragen

Wie hoch ist die Interviewrate (Wie viele Kandidaten werden eingeladen)? ***

Interview Rate: 18.00%

Wie viele eingeladene Kandidaten nehmen tatsächlich am Interview teil? ***

Interview Completion Rate: 90.52%

Wie viele Kandidaten verlassen den Prozess zwischen Einladung und Interview freiwillig? ***

Pre Interview Dropout Rate: 9.48%

Wie viele Kandidaten lehnen ein Job-Angebot nach einem Interview ab? ***

Offers Made: 172

Abgelehnte Job-Angebote: 52

Offer Decline Rate: 30.23%

3. Data Preparation

Deskriptive Statistik für Wartezeiten (waiting_days_since_last_event) ●●●

Anzahl Werte: 17794
Mittelwert: 4.09
Median: 3.00
Minimum: 0.0
Maximum: 90.0
Standardabweichung: 4.14
1. Quartil (25%): 2.00
2. Quartil (50% / Median): 3.00
3. Quartil (75%): 5.00
Schiefe (Skewness): 7.97
Kurtosis: 115.97

Anzahl abgeschlossene Hires: 110
Mittelwert Time to Hire: 43.29 Tage
Median Time to Hire: 40.5


Prozess-KPIs berechnen ●●●

	KPI	Start Event	End Event	Count	Mean	Median	Min	Max	Std
0	Time to Review	Application Received	Application Reviewed	7350	3.27	3.00	1	9	1.85
1	Time to Interview	Application Received	Interview Completed	1222	18.56	18.00	6	46	6.75
2	Time to Offer	Application Received	Offer Made	172	25.05	24.00	10	49	7.32
3	Time to Contract	Offer Accepted	Contract Signed	110	13.33	12.00	5	30	5.30
4	Time to Start	Contract Signed	Employment Started	110	33.69	30.00	0	90	24.27
5	Total Time to Hire	Application Received	Contract Signed	110	43.29	40.50	21	74	11.90



Wartezeiten ohne NULL-Werte ●●●

Histogramm der Wartezeiten ●●●

Verteilung der Wartezeiten



4. Modelling – Explorative Datenanalyse



5. Bewertung & Erkenntnis



Lediglich der Standort Frankfurt zeigt einen statistisch signifikanten Zusammenhang.



Ich habe die falsche Zielvariable untersucht.



Ich habe die Businessfrage nicht beantworten können.



Ich habe meine gewünschten Effekte nicht bei der Datengenerierung berücksichtigt.

6. Zurück zum Modelling

Multiple Lineare Regression

- Das Modell erklärt **70%** der beobachteten Unterschiede
- Modell ist insgesamt statistisch signifikant

Multiple Lineare Regression – ohne Frankfurt

- Das Modell erklärt nur noch **11%** der Varianz, 89% der Unterschiede in der Time to Hire bleiben ungeklärt
- Das Modell ist statistisch nicht signifikant

7. Fazit: meine Hypothese konnte nicht bestätigt werden

! **Business first**
Die Qualität der Analyse beginnt bei der Businessfrage.

! **Data follows the question**
Das Datenmodell muss die relevanten Einflussgrößen abbilden.

! **Define KPIs precisely**
Unklare Kennzahlen führen zu unklaren Ergebnissen.

! **No significance $\neq$ no insight**
Auch nicht signifikante Ergebnisse liefern Erkenntnisse über Daten und Modell.

8. Was ich heute anders machen würde

Vor der Datengenerierung würde ich aus der Businessfrage zunächst ein Wirkmodell ableiten und sicherstellen, dass der synthetische Datensatz die dafür notwendigen Variablen und realistischen Zusammenhänge enthält. Für diesen Case wären das insbesondere Prozesszeiten, freiwillige Dropouts, Candidate Experience, Recruiting-Aufwände und Vakanzkosten. Erst damit ließe sich der wirtschaftliche Nutzen einer Prozessverkürzung belastbar modellieren.